

RAPPORT TECHNIQUE

Aujourd'hui, le secteur agricole fait face à plusieurs difficultés majeures liées aux conditions climatiques. En effet, les agriculteurs sont confrontés à des phénomènes tels que la variabilité des températures, les sécheresses, les inondations ainsi que l'imprévisibilité des précipitations. Ces facteurs impactent directement la production agricole et rendent la planification des activités (semis, irrigation, récolte) plus complexe.

En Afrique, et particulièrement au Sénégal, ces problèmes représentent un enjeu important pour la sécurité alimentaire. L'agriculture dépend fortement des conditions météorologiques, qui deviennent de plus en plus instables en raison du changement climatique surtout au niveau de la pluviométrie.

Face à ces défis, il devient nécessaire de disposer de données météorologiques fiables et en temps réel afin d'améliorer la prise de décision.

Dans ce contexte, ce projet propose la mise en place d'un pipeline de données météo automatisé basé sur les services cloud d'Amazon Web Services (AWS). Ce système permet de collecter, stocker, traiter et analyser des données climatiques afin d'aider à une meilleure gestion des activités agricoles.

Objectifs du projet

L'objectif principal de ce projet est de concevoir un pipeline de données automatisé permettant de collecter et d'exploiter des informations météorologiques en temps réel.

Plus précisément, il s'agit de :

- Collecteur automatique de données météo pour plusieurs villes

- Stocker ces données de manière fiable et évolutive
- Traiter et structurer les données pour les rendre exploitables
- Fournir des informations utiles pour la prise de décision agricole
- Automatiser l'ensemble du processus sans intervention humaine

Ce projet vise ainsi à démontrer l'utilisation des technologies cloud dans le domaine de l'agriculture intelligente (AgriTech).

Architecture du système

Le système est mis en place sur une architecture serverless basée sur les services cloud d'Amazon Web Services (AWS). Il permet de collecter, stocker, traiter et analyser automatiquement des données météorologiques.

Le fonctionnement global du pipeline est basé sur un flux de données structuré en plusieurs étapes :

1. Collecte des données

Une fonction AWS Lambda, appelée *lambda-meteo-fonction*, est responsable de la collecte des données météorologiques à partir de l'API OpenWeatherMap.

Cette fonction se déclenche automatiquement à intervalles réguliers grâce à Amazon EventBridge.

2. Stockage des données brutes

Les données enregistrées sont ensuite stockées dans Amazon S3 sous forme de fichiers JSON. Ce stockage permet de conserver une trace des données brutes pour une éventuelle réutilisation ou analyse future.

3. Traitement des données

Une deuxième fonction Lambda, appelée *lambda-meteo-traitement*, est déclenchée automatiquement lors de l'ajout d'un fichier dans S3.

Cette fonction lit les données, les nettoie et les restructure afin de les rendre exploitables.

4. Stockage structuré

Les données traitées sont ensuite enregistrées dans une table Amazon DynamoDB. Cette base de données NoSQL permet un accès rapide et efficace aux informations météorologiques.

5. Export des données

Une troisième fonction Lambda, *lambda-meteo-export*, permet de générer des fichiers CSV à partir des données stockées dans DynamoDB. Ces fichiers sont ensuite enregistrés dans S3 pour être utilisés dans des analyses ou des visualisations.

6. Suivi et surveillance

Amazon CloudWatch est utilisé pour surveiller le fonctionnement des différentes fonctions Lambda. Des alarmes sont mises en place afin de détecter les erreurs ou anomalies dans le système.

7. Automatisation

L'ensemble du pipeline est automatisé grâce à Amazon EventBridge, qui déclenche les fonctions Lambda à des intervalles réguliers sans intervention humaine.

Technologies utilisées

Dans le cadre de ce projet, plusieurs technologies ont été utilisées afin de mettre en place un pipeline de données automatisé et efficace.

- **AWS Lambda**

AWS Lambda est utilisé pour exécuter le code sans avoir à gérer de serveur. Il permet de traiter les données météo de manière automatique et scalable.

- **Amazon S3**

Amazon S3 est utilisé pour stocker les données brutes ainsi que les fichiers exportés (CSV). Il offre un stockage fiable et sécurisé.

- **Amazon DynamoDB**

DynamoDB est une base de données NoSQL utilisée pour stocker les données traitées. Elle permet un accès rapide et une bonne gestion des données en temps réel.

- **Amazon EventBridge**

EventBridge permet d'automatiser le déclenchement des fonctions Lambda selon un intervalle de temps défini.

- **Amazon CloudWatch**

CloudWatch est utilisé pour surveiller le fonctionnement du système, afficher les logs et déclencher des alertes en cas de problème.

- **Python**

Le langage Python est utilisé pour développer les fonctions Lambda, en raison de sa simplicité et de sa compatibilité avec AWS.

- **API OpenWeatherMap**

Cette API permet de récupérer les données météorologiques en temps réel pour différentes villes.

Implémentation des fonctions Lambda

Le système repose sur trois fonctions AWS Lambda qui assurent chacune un rôle spécifique dans le pipeline de traitement des données météorologiques.

1. Lambda de collecte des données (*lambda-meteo-fonction*)

Cette fonction a pour rôle principal de collecter les données météorologiques à partir de l'API OpenWeatherMap pour plusieurs villes.

Elle est déclenchée automatiquement grâce à Amazon EventBridge selon une planification définie.

Fonctionnement :

- Envoi d'une requête HTTP vers l'API météo
- Récupération des données au format JSON
- Extraction des informations principales (température, humidité, pression, etc.)
- Structuration des données
- Enregistrement dans Amazon S3 (données brutes)
- Insertion dans DynamoDB

Exemple de code commenté :

```
# Appel à l'API météo
response = urllib.request.urlopen(url)
data = json.loads(response.read())

# Extraction des données principales
temperature = round(data["main"]["temp"], 1)
humidite = data["main"]["humidity"]

# Création d'un objet structuré
result = {
    "ville": data["name"],
    "temperature": temperature,
    "humidite": humidite,
    "timestamp": datetime.utcnow().isoformat()
}

# Stockage dans S3
s3.put_object(
    Bucket=bucket_name,
    Key=file_name,
    Body=json.dumps(result)
)

# Stockage dans DynamoDB
table.put_item(Item=result)
```

2. Lambda de traitement (*lambda-meteo-traitement*)

Cette fonction est déclenchée automatiquement lorsqu'un nouveau fichier est ajouté dans le bucket S3.

Elle permet de traiter les données brutes afin de les rendre exploitables.

Fonctionnement :

- Lecture du fichier JSON depuis S3
- Nettoyage des données
- Vérification des champs
- Structuration finale
- Insertion dans DynamoDB

Elle garantit la qualité et la cohérence des données.

3. Lambda d'export (*lambda-meteo-export*)

Cette fonction permet d'exporter les données stockées dans DynamoDB vers un fichier CSV.

Fonctionnement :

- Lecture des données depuis DynamoDB
- Conversion en format CSV
- Enregistrement dans S3

Cela permet d'utiliser les données pour :

- Analyse
- Visualisation
- Reporting

Stockage des données

Dans ce projet, le stockage des données repose sur deux services principaux : Amazon S3 et Amazon DynamoDB. Ces deux services jouent des rôles complémentaires dans le pipeline.

1. Stockage des données brutes avec Amazon S3

Les données météorologiques collectées depuis l'API sont d'abord stockées dans Amazon S3 sous forme de fichiers JSON.

Chaque fichier est organisé selon une structure hiérarchique basée sur la date et la ville, par exemple :

raw/année/mois/jour/ville/data.json

Cette organisation permet de :

- Conserver un historique complet des données
- Faciliter la recherche et l'accès aux fichiers
- Permettre une réutilisation future des données

Amazon S3 est particulièrement adapté pour le stockage de données brutes grâce à sa haute durabilité et sa capacité à gérer de grands volumes de données.

2. Stockage des données traitées avec DynamoDB

Après traitement, les données sont stockées dans une table Amazon DynamoDB.

Chaque enregistrement contient des informations telles que :

- La ville
- La température
- L'humidité
- La date

Une clé unique est utilisée pour éviter les doublons (par exemple : *ville* + *date*).

DynamoDB permet :

- Un accès rapide aux données
- Une bonne scalabilité
- Une gestion efficace des données en temps réel

3. Avantages de cette architecture de stockage

L'utilisation combinée de S3 et DynamoDB permet de séparer :

- Les données brutes (S3)
- Les données traitées et exploitables (DynamoDB)

Cette approche améliore la fiabilité du système et facilite l'analyse des données.

Automatisation et surveillance

Afin de garantir un fonctionnement autonome et fiable du pipeline de données, des mécanismes d'automatisation et de surveillance ont été mis en place à l'aide des services AWS.

1. Automatisation avec EventBridge

Amazon EventBridge est utilisé pour déclencher automatiquement la fonction *lambda-meteo-fonction* selon une planification définie (cron).

Cela permet de collecter les données météorologiques à intervalles réguliers sans intervention humaine.

Grâce à cette automatisation :

- Les données sont mises à jour en continu
- Le système fonctionne de manière autonome
- Le risque d'erreur humaine est réduit

2. Déclenchement automatique via S3

Lorsque de nouvelles données sont stockées dans Amazon S3, cela déclenche automatiquement la fonction *lambda-meteo-traitement*.

Ce mécanisme permet de :

- Traiter les données en temps réel
- Éviter les retards dans le pipeline
- Maintenir une chaîne de traitement fluide

3. Surveillance avec CloudWatch

Amazon CloudWatch est utilisé pour surveiller le bon fonctionnement des fonctions Lambda.

Il permet de :

- Visualiser les logs d'exécution
- Détecter les erreurs
- Analyser les performances

4. Mise en place d'alarmes

Des alarmes CloudWatch ont été configurées afin de détecter les anomalies (erreurs Lambda, problèmes de performances, etc.).

Lorsqu'un problème est détecté :

- Une alerte est envoyée via Amazon SNS
- L'utilisateur reçoit une notification par e-mail

5. Avantages du suivi

Le monitoring permet :

- D'assurer la fiabilité du système
- D'identifier rapidement les erreurs
- D'améliorer la maintenance du pipeline

Justification des choix techniques

Dans le cadre de ce projet, plusieurs choix technologiques ont été faits afin d'assurer la performance, la scalabilité et la simplicité de mise en œuvre du système.

1. DynamoDB vs RDS

DynamoDB a été choisi au lieu d'une base de données relationnelle (RDS) pour les raisons suivantes :

- Les données météo sont **semi-structurées**
- Il n'y a pas besoin de relations complexes entre les données
- DynamoDB offre une **meilleure performance en lecture/écriture rapide**
- Il est plus simple à gérer (serverless)

RDS aurait été utile dans un cas avec :

- des relations complexes (tables liées)
- des requêtes SQL avancées

Dans ce projet, DynamoDB est donc plus adapté.

2. S3 pour le stockage des données brutes

Amazon S3 a été choisi pour :

- Sa grande capacité de stockage
- Sa durabilité élevée
- Sa simplicité d'utilisation
- Sa compatibilité avec les autres services AWS

Il permet de conserver un historique complet des données.

3. Architecture serverless

Le choix d'une architecture serverless permet :

- Une meilleure scalabilité
- Une réduction des coûts
- Une simplification du déploiement
- Une automatisation complète du pipeline

Conclusion

Ce projet a permis de mettre en place un pipeline de données météorologiques entièrement automatisé à l'aide des services AWS.

Il a démontré l'intérêt des technologies cloud dans le domaine de l'agriculture, notamment pour améliorer la prise de décision basée sur des données fiables et actualisées.

Grâce à l'utilisation d'une architecture serverless, le système est évolutif, efficace et nécessite peu de maintenance.

Cependant, certaines améliorations peuvent être envisagées, comme l'ajout de visualisations avancées ou l'intégration d'autres sources de données.

Ce projet constitue ainsi une base solide pour le développement de solutions innovantes en AgriTech.